

איסוף נתוני סרטים - חלק 1 - דוח

מגישות: מרים דינאי 212296099 | הילה הלבפשט 032540668

מקורות הנתונים:

1. IMDb Non-Commercial Datasets - השתמשנו בארבעה מאגרי הנתונים הציבוריים של IMDb, אותם הורדנו מהכתובת:
<https://developer.imdb.com/non-commercial-datasets>
2. Wikipedia (Web Scraping)

החלטות שנלקחו בבניית סט הנתונים:

1. סינון הנתונים מ-IMDb - התמקדנו בסרטים בלבד, המתחילים באות L / I, שיצאו עד שנת 2024 וזמן ההרצה שלהם הוא בין 60 ל-300 דק'.
2. צמצמנו את הנתונים שלנו מ-22,427 שורות ל-5000 בהמשך להנחיית המרצה. החלטנו לבחור שורות סרטים בעלי מספר ההצבעות הגבוה ביותר בקרב הסרטים, ובנוסף שאין בהם ערכים חסרים בעמודות החובה מ-IMDb. הסיבות לבחירה זו היא שלדעתנו סרטים פופולריים הם בעלי סבירות גבוהה הרבה יותר להופיע בויקיפדיה ולכן יקטין את אחוזי הערכים החסרים בעמודות שמגיעות ממנה וישפר באופן ניכר את ביצועי המודלים בחלק השני והשלישי של הפרויקט.
3. קובץ title.principals.tsv מכיל מאות מיליוני שורות, ולא ניתן לטעון אותו לזיכרון בבת אחת. פתרנו זאת על ידי קריאה בחלקים של 200,000 שורות בכל פעם. בכל חלק סיננו פעמיים: ראשית רק שורות שבהן category הוא 'actor' או 'actress', ושנית רק שורות שבהן tconst מופיע ברשימת הסרטים שלנו.
4. בעת כריית הנתונים מויקיפדיה, נתקלנו בערכים במטבעות שהם לא דולר כפי שצוין בדרישות המטלה. לצורך כך, השתמשנו בספריית CurrencyConverter לביצוע המרה היסטורית המבוססת על שנת יציאת הסרט, מה שמבטיח עקביות ויכולת השוואה מדויקת בין הסרטים השונים בסט הנתונים.
5. החלטנו לשמור את דפי ה-HTML של ויקיפדיה בתיקייה מקומית במחשב לאחר ההורדה הראשונה. צעד זה איפשר לנו לבצע תיקונים בקוד ולהריץ אותו שוב במהירות מבלי לבצע קריאות חוזרות לשרת. בנוסף, הגדרנו שמירה אוטומטית של הנתונים בכל 100 שורות, החלטה זו הבטיחה שבמקרה של קריסת הקוד או ניתוק אינטרנט, המידע שכבר נאסף יישמר במערכת ולא ילך לאיבוד.
6. במהלך דגימות אקראיות שביצענו לתוצאות כריית הנתונים, זיהינו חוסר אחידות במבנה הדפים בוויקיפדיה שגרם לנתונים חסרים. השדות ב-Infobox הופיעו לעיתים ביחיד ולעיתים ברבים (כמו "country" לעומת "countries"), ולכן הגמשנו את תנאי החיפוש בקוד כך שיכסה את כל ההטיות. בנוסף, גילינו שלסרטים מסוימים יש פורמט שונה של כתובת URL (למשל סרטים אמריקאים שקיבלו את התוספת American_film). בעקבות זאת, הרחבנו את מנגנון החיפוש של הפונקציה כך שינסה מספר תבניות שונות של כותרות, מה שהקטין את כמות הערכים החסרים בסט הנתונים הסופי שלנו.

תיאור השדות:

שם השדה	תיאור	טיפוס	מקור
tconst	מזהה ייחודי של הסרט ב-IMDb	String	IMDb (title.basics)
primaryTitle	שם הסרט	String	IMDb (title.basics)
startYear	שנת יציאה לאקרנים	Integer	IMDb (title.basics)
genres	רשימת ז'אנרים (מופרדת בפסיקים)	String	IMDb (title.basics)
lead_actors_ids	רשימת nconst של 5 השחקנים המובילים	List of Strings	IMDb (title.principals)

IMDb (title.basics)	Integer	אורך הסרט בדקות	runtimeMinutes
IMDb (title.ratings)	Float	ממוצע דירוג IMDb (1.0-10.0)	averageRating
IMDb (title.ratings)	Integer	מספר ההצבעות לדירוג	numVotes
Wikipedia	String	השפה הראשית בסרט	Language
Wikipedia	String	המדינה בה הופק הסרט	Country
Wikipedia	Float	תקציב הפקה במיליוני USD (ממוצע אם טווח)	budget
Wikipedia	Float	הכנסות גלובליות במיליוני USD (ממוצע אם טווח)	BoxOffice
Wikipedia	String	תקציר עלילת הסרט	plot

נתונים מספריים וערכים חסרים:

- מספר סרטים שנאספו: 5,000
- ניתוח ערכים חסרים:
 - בעמודות המקור מ-IMDb (שנה, ז'אנר, דירוג): 0% חסרים
 - **Country & Language**: כ-41% חסרים (סרטים ללא ערך תואם בוויקיפדיה או ללא Infobox מפורט).
 - **BoxOffice & Budget**: כ-81%-85% חסרים.
 - **Plot**: כ-49% חסרים.

שם השדה	אחוז ערכים חסרים	מספר ערכים חסרים
tconst	0%	0
primaryTitle	0%	0
startYear	0%	0
genres	0%	0
lead_actors_ids	0%	0
runtimeMinutes	0%	0
averageRating	0%	0
numVotes	0%	0
Language	41.08%	2,054
Country	41.44%	2,072
plot	49.24%	2,462
BoxOffice	81.06%	4,053
budget	85.22%	4,261